

# Document de travail - Modèle processus gaussiens

Arthur Leroy

09 décembre, 2019

## 1 Une cargaison de notations

- $M$  le nombre d'individus,
- $N$  le nombre d'observation par individu,
- $i, j$  les indices pour les individus,
- $k, l$  les indices pour les observations,

On dispose d'un échantillon  $\{(y_i^N, t_i^N)\}_{i=1, \dots, M}$ , tel que:

- $t^N = (t_1, \dots, t_N)^T$  le vecteur des temps de l'individu  $i$  (communs à tous),
- $y_i^N = y_i(t^N) = (y_i(t_1), \dots, y_i(t_N))^T$  le vecteur des observations de l'individu  $i$ ,
- $t^O \in \mathbb{R}^O$ ,  $t^O \subset t^N$  le vecteur des temps d'observation d'un nouvel individu  $*$ ,
- $t^P \in \mathbb{R}^P$ ,  $t^P \subset t^N$  le vecteur des temps à prédire d'un nouvel individu  $*$ ,
- $O + P = N$  et  $t_i^O \cup t_i^P = t_i^N, \forall i$
- $y_i^O = y_i(t^O)$ ,  $y_i^P = y_i(t^P)$ ,  $\forall i$
- $K_{\theta_0}$  une noyau d'hyperparamètres  $\theta_0$
- $(\Sigma_{\theta_i})_i$  un ensemble de noyau de même forme et d'hyperparamètres respectifs  $(\theta_i)_i$
- $\sigma^2 \in R$
- $\Theta = \{\theta_0, (\theta_i)_i, \sigma^2\}$  le vecteur des hyperparamètres du modèle

L'utilisation des indices avec les autres objets est cohérente avec celle ci-dessus.

## 2 Le modèle et les hypothèses

On pose le modèle suivant:

$$\forall i, \forall t, y_i(t) = \mu_0(t) + f_i(t) + \epsilon_i(t)$$

- $\mu_0(\cdot) \sim GP(0, K_{\theta_0}(\cdot, \cdot))$
- $f_i(\cdot) \sim GP(0, \Sigma_{\theta_i}(\cdot, \cdot))$ ,  $(f_i)_i \perp\!\!\!\perp$
- $\epsilon_i(t) \sim \mathcal{N}(0, \sigma^2)$ ,  $(\epsilon_i)_i \perp\!\!\!\perp, \forall t \in R$
- $\mu_0 \perp\!\!\!\perp (f_i)_i$

On note:  $\Psi_i(\cdot, \cdot) = \Sigma_{\theta_i}(\cdot, \cdot) + \sigma^2 I_d$

$$y_i(\cdot) | \mu_0 \sim GP(\mu_0(\cdot), \Psi_i(\cdot, \cdot)), (y_i | \mu_0)_i \perp\!\!\!\perp$$

Si on applique cela à notre échantillon, on a la loi a priori suivante:

$$y_i^N | \mu_0^N \sim \mathcal{N}(\mu_0^N, \Psi_i^N)$$

avec

$$\Psi_i^N = \begin{pmatrix} \Psi_i^{O,O} & \Psi_i^{O,P} \\ \Psi_i^{P,O} & \Psi_i^{P,P} \end{pmatrix}$$

### 3 Prédiction pour un nouvel individu partiellement observé

#### 3.1 Calcul de la loi a posteriori

L'objectif réside dans la prédiction de  $p(y_*^P | y_*^O, (y_i^N)_i)$ , la loi des temps à prédire sachant les temps observés du nouvel individu  $*$  et les observations des autres individus.

Tout d'abord, on sait que:

$$\begin{aligned} p(y_*^N | (y_i^N)_i) &= \int p(y_*^N, \mu_0^N | (y_i^N)_i) d\mu_0^N \\ &= \int p(y_*^N | (y_i^N)_i, \mu_0^N) p(\mu_0^N | (y_i^N)_i) d\mu_0^N \\ &\stackrel{(y_i | \mu_0)_i \perp\!\!\!\perp}{=} \int p(y_*^N | \mu_0^N) p(\mu_0^N | (y_i^N)_i) d\mu_0^N \end{aligned}$$

Et par définition du modèle,

$$p(y_*^N | \mu_0^N) = \mathcal{N}(\mu_0^N, \Psi_*^N) = \mathcal{N}\left(\begin{bmatrix} \mu_0^{O,N} \\ \mu_0^{P,N} \end{bmatrix}, \begin{pmatrix} \Psi_*^{O,O} & \Psi_*^{O,P} \\ \Psi_*^{P,O} & \Psi_*^{P,P} \end{pmatrix}\right)$$

De plus, si on fait l'hypothèse (qui sera démontrée dans le paragraphe 2 sur l'apprentissage) que:

$$p(\mu_0^N | (y_i^N)_i) = \mathcal{N}(m^N, \hat{K}^N) = \mathcal{N}\left(\begin{bmatrix} m^O \\ m^P \end{bmatrix}, \begin{pmatrix} \hat{K}^{O,O} & \hat{K}^{O,P} \\ \hat{K}^{P,O} & \hat{K}^{P,P} \end{pmatrix}\right)$$

Avec:

- $\hat{K}^N = \left( (K^N)^{-1} + \sum_{i=1}^M (\Psi_i^N)^{-1} \right)^{-1}$
- $m^N = \hat{K}^N \sum_{i=1}^M (\Psi_i^N)^{-1} y_i^N$

Alors on obtient que:

$$p(y_*^N | (y_i^N)_i) = \mathcal{N}(m_*^N, \Gamma_*^N) = \mathcal{N}\left(\begin{bmatrix} m_*^O \\ m_*^P \end{bmatrix}, \begin{pmatrix} \Gamma_*^{O,O} & \Gamma_*^{O,P} \\ \Gamma_*^{P,O} & \Gamma_*^{P,P} \end{pmatrix}\right) \quad (1)$$

Avec:

- $m_*^N = m_*^N$
- $\Gamma_*^N = \Psi_*^N + \hat{K}^N$

De plus, en utilisant la formule de prédiction des processus Gaussiens (voir Bishop section 2.3.1), on obtient que:

$$p(y_*^P | y_*^O, (y_i^N)_i) = \mathcal{N}(m_*^P + \Gamma_*^{P,O} (\Gamma_*^{O,O})^{-1} (y_*^O - m_*^O), \Gamma_*^{P,P} - \Gamma_*^{P,O} (\Gamma_*^{O,O})^{-1} \Gamma_*^{O,P}) \quad (2)$$

## 4 L'apprentissage

### 4.1 Etape E:

$$\begin{aligned}
p(\mu_0^N | (y_i^N)_i, \Theta) &\propto \overbrace{p((y_i^N)_i | \mu_0^N, \sigma^2, (\theta_{\theta_i})_i)}^{\prod_{i=1}^M \mathcal{N}(\mu_0^N, \Psi_i^N)} \overbrace{p(\mu_0^N | \theta_0)}^{\mathcal{N}(0, K_{\theta_0})} \\
\ln p(\mu_0^N | (y_i^N)_i, \Theta) &= -\frac{1}{2} \mu_0^{NT} K_{\theta_0}^{-1} \mu_0^N - \frac{1}{2} \sum_{i=1}^M -2 y_i^{NT} \Psi_i^{N-1} \mu_0^N + \mu_0^{NT} \Psi_i^{N-1} \mu_0^N + C_1 \\
&= -\frac{1}{2} \mu_0^{NT} (K_{\theta_0}^{-1} + \sum_{i=1}^M \Psi_i^{N-1}) \mu_0^N - \mu_0^N \sum_{i=1}^M \Psi_i^{N-1} y_i^N + C_1
\end{aligned}$$

Ainsi:

$$p(\mu_0^N | (y_i^N)_i, \Theta) = \mathcal{N}(m^N, \hat{K}^N)$$

Avec:

- $\hat{K}^N = \left( (K_{\theta_0}^N)^{-1} + \sum_{i=1}^M (\Psi_i^N)^{-1} \right)^{-1}$
- $m^N = \hat{K}^N \sum_{i=1}^M (\Psi_i^N)^{-1} y_i^N$

## 5 Les preuves associées

Pour les démonstrations, on va user et abuser du Lemme ci dessous.

**Lemma 1.** Pour un espace  $\mathcal{X}$  qui permet d'utiliser Fubini ,

$$\forall A, B \in \mathcal{X}, \quad \mathbb{E}_{p(A)} [g(A)] = \mathbb{E}_{p(B)} [\mathbb{E}_{p(A|B)} [g(A)]]$$

*Proof.*

$$\begin{aligned}
\mathbb{E}_{p(A)} [g(A)] &= \int g(A) p(A) dA \\
&= \int g(A) \int p(A, B) dB dA \\
&= \int \int g(A) p(A|B) p(B) dB dA \\
&\stackrel{\text{Fubini}}{=} \int \left( \int g(A) p(A|B) dA \right) p(B) dB \\
&= \mathbb{E}_{p(B)} [\mathbb{E}_{p(A|B)} [g(A)]]
\end{aligned}$$

□

### 5.1 Preuve de (1)

On sait que la convolution de deux gaussiennes est elle aussi gaussienne, il suffit donc de calculer ses paramètres à l'aide du Lemme 1 avec  $A = y_*^N | (y_i^N)_i$  et  $B = \mu_0^N | (y_i^N)_i$

$$\begin{aligned}
m_*^N &= \mathbb{E}_{p(y_*^N | (y_i^N)_i)} [y_*^N] \\
&= \mathbb{E}_{p(\mu_0^N | (y_i^N)_i)} \left[ \mathbb{E}_{p(y_*^N | (y_i^N)_i, \mu_0^N)} [y_*^N] \right] \\
&= \mathbb{E}_{p(\mu_0^N | (y_i^N)_i)} \left[ \mathbb{E}_{p(y_*^N | y_i^{t_i}, \mu_0^{t_i^*})} [y_*^N] \right] \\
&= \mathbb{E}_{p(\mu_0^N | (y_i^N)_i)} [\mu_0^N] \\
&= m^N
\end{aligned}$$

On calcule ensuite le moment d'ordre 2:

$$\begin{aligned}
\mathbb{E}_{p(y_*^N | (y_i^N)_i)} [y_*^N y_*^{N^T}] &= \mathbb{E}_{p(\mu_0^N | (y_i^N)_i)} \left[ \mathbb{E}_{p(y_*^N | (y_i^N)_i, \mu_0^N)} [y_*^N y_*^{N^T}] \right] \\
&= \mathbb{E}_{p(\mu_0^N | (y_i^N)_i)} \left[ \underbrace{\Psi_*^N}_{\mathbb{V}_{p(y_*^N | (y_i^N)_i)}[y_*^N]} + \underbrace{\mu_0^N \mu_0^{N^T}}_{\mathbb{E}_{p(y_*^N | (y_i^N)_i)}[y_*^N] \mathbb{E}_{p(y_*^N | (y_i^N)_i)}[y_*^{N^T}]} \right] \\
&= \Psi_*^N + \mathbb{E}_{p(\mu_0^N | (y_i^N)_i)} [\mu_0^N \mu_0^{N^T}] \\
&= \Psi_*^N + \underbrace{\hat{K}^N}_{\mathbb{V}_{p(\mu_0^N | (y_i^N)_i)}(\mu_0^N)} + \underbrace{m^N m^{N^T}}_{\mathbb{E}_{p(\mu_0^N | (y_i^N)_i)}[\mu_0^N] \mathbb{E}_{p(\mu_0^N | (y_i^N)_i)}[\mu_0^{N^T}]}
\end{aligned}$$

Ainsi:

$$\begin{aligned}
\Gamma_*^N &= \mathbb{V}_{p(y_*^N | (y_i^N)_i)} [y_*^N] \\
&= \mathbb{E}_{p(y_*^N | (y_i^N)_i)} [y_*^N y_*^{N^T}] - \mathbb{E}_{p(y_*^N | (y_i^N)_i)} [y_*^N] \mathbb{E}_{p(y_*^N | (y_i^N)_i)} [y_*^{N^T}] \\
&= \Psi_*^N + \hat{K}^N + m^N m^{N^T} - m^N m^{N^T} \\
&= \Psi_*^N + \hat{K}^N
\end{aligned}$$