

Document de travail - Modèle processus gaussiens

Arthur Leroy

10 mars, 2020

1 Une cargaison de notations

- M le nombre d'individus,
- N le nombre d'observation par individu,
- i, j les indices pour les individus,
- k, l les indices pour les observations,

On dispose d'un échantillon $\{(y_i^N, t_i^N)\}_{i=1, \dots, M}$, tel que:

- $t^N = (t_1, \dots, t_N)^T$ le vecteur des temps de l'individu i (communs à tous),
- $y_i^N = y_i(t^N) = (y_i(t_1), \dots, y_i(t_N))^T$ le vecteur des observations de l'individu i ,
- $t^O \in \mathbb{R}^O$, $t^O \subset t^N$ le vecteur des temps d'observation d'un nouvel individu $*$,
- $t^P \in \mathbb{R}^P$, $t^P \subset t^N$ le vecteur des temps à prédire d'un nouvel individu $*$,
- $O + P = N$ et $t_i^O \cup t_i^P = t_i^N, \forall i$
- $y_i^O = y_i(t^O)$, $y_i^P = y_i(t^P)$, $\forall i$
- K_{θ_0} une noyau d'hyperparamètres θ_0
- $(\Sigma_{\theta_i})_i$ un ensemble de noyau de même forme et d'hyperparamètres respectifs $(\theta_i)_i$
- $\sigma^2 \in R$
- $\Theta = \{\theta_0, (\theta_i)_i, \sigma^2\}$ le vecteur des hyperparamètres du modèle

L'utilisation des indices avec les autres objets est cohérente avec celle ci-dessus.

2 Le modèle et les hypothèses

On pose le modèle suivant:

$$\forall i, \forall t, y_i(t) = \mu_0(t) + f_i(t) + \epsilon_i(t)$$

- $\mu_0(\cdot) \sim GP(0, K_{\theta_0}(\cdot, \cdot))$
- $f_i(\cdot) \sim GP(0, \Sigma_{\theta_i}(\cdot, \cdot))$, $(f_i)_i \perp\!\!\!\perp$
- $\epsilon_i(t) \sim \mathcal{N}(0, \sigma^2)$, $(\epsilon_i)_i \perp\!\!\!\perp, \forall t \in R$
- $\mu_0 \perp\!\!\!\perp (f_i)_i$

On note: $\Psi_i(\cdot, \cdot) = \Sigma_{\theta_i}(\cdot, \cdot) + \sigma^2 I_d$

$$y_i(\cdot) | \mu_0 \sim GP(\mu_0(\cdot), \Psi_i(\cdot, \cdot)), (y_i | \mu_0)_i \perp\!\!\!\perp$$

Si on applique cela à notre échantillon, on a la loi a priori suivante:

$$y_i^N | \mu_0^N \sim \mathcal{N}(\mu_0^N, \Psi_i^N)$$

avec

$$\Psi_i^N = \begin{pmatrix} \Psi_i^{O,O} & \Psi_i^{O,P} \\ \Psi_i^{P,O} & \Psi_i^{P,P} \end{pmatrix}$$

3 Prédiction pour un nouvel individu partiellement observé

3.1 Calcul de la loi a posteriori

L'objectif réside dans la prédiction de $p(y_*^P | y_*^O, (y_i^N)_i)$, la loi des temps à prédire sachant les temps observés du nouvel individu * et les observations des autres individus.

Tout d'abord, on sait que:

$$\begin{aligned} p(y_*^N | (y_i^N)_i) &= \int p(y_*^N, \mu_0^N | (y_i^N)_i) d\mu_0^N \\ &= \int p(y_*^N | (y_i^N)_i, \mu_0^N) p(\mu_0^N | (y_i^N)_i) d\mu_0^N \\ &\stackrel{(y_i | \mu_0)_i \perp\!\!\!\perp}{=} \int p(y_*^N | \mu_0^N) p(\mu_0^N | (y_i^N)_i) d\mu_0^N \end{aligned}$$

Et par définition du modèle,

$$p(y_*^N | \mu_0^N) = \mathcal{N}(\mu_0^N, \Psi_*^N) = \mathcal{N}\left(\begin{bmatrix} \mu_0^{O,N} \\ \mu_0^{P,N} \end{bmatrix}, \begin{pmatrix} \Psi_*^{O,O} & \Psi_*^{O,P} \\ \Psi_*^{P,O} & \Psi_*^{P,P} \end{pmatrix}\right)$$

De plus, si on fait l'hypothèse (qui sera démontrée dans le paragraphe 2 sur l'apprentissage) que:

$$p(\mu_0^N | (y_i^N)_i) = \mathcal{N}(m^N, \hat{K}^N) = \mathcal{N}\left(\begin{bmatrix} m^O \\ m^P \end{bmatrix}, \begin{pmatrix} \hat{K}^{O,O} & \hat{K}^{O,P} \\ \hat{K}^{P,O} & \hat{K}^{P,P} \end{pmatrix}\right)$$

Avec:

- $\hat{K}^N = \left((K^N)^{-1} + \sum_{i=1}^M (\Psi_i^N)^{-1} \right)^{-1}$
- $m^N = \hat{K}^N \sum_{i=1}^M (\Psi_i^N)^{-1} y_i^N$

Alors on obtient que:

$$p(y_*^N | (y_i^N)_i) = \mathcal{N}(m_*^N, \Gamma_*^N) = \mathcal{N}\left(\begin{bmatrix} m_*^O \\ m_*^P \end{bmatrix}, \begin{pmatrix} \Gamma_*^{O,O} & \Gamma_*^{O,P} \\ \Gamma_*^{P,O} & \Gamma_*^{P,P} \end{pmatrix}\right) \quad (1)$$

Avec:

- $m_*^N = m^N$
- $\Gamma_*^N = \Psi_*^N + \hat{K}^N$

De plus, en utilisant la formule de prédiction des processus Gaussiens (voir Bishop section 2.3.1), on obtient que:

$$p(y_*^P | y_*^O, (y_i^N)_i) = \mathcal{N}(m_*^P + \Gamma_*^{P,O} (\Gamma_*^{O,O})^{-1} (y_*^O - m_*^O), \Gamma_*^{P,P} - \Gamma_*^{P,O} (\Gamma_*^{O,O})^{-1} \Gamma_*^{O,P}) \quad (2)$$

4 L'apprentissage

4.1 Etape E:

$$\begin{aligned}
p(\mu_0^N | (y_i^N)_i, \Theta) &\propto \overbrace{p((y_i^N)_i | \mu_0^N, \sigma^2, (\theta_{\theta_i})_i)}^{\prod_{i=1}^M \mathcal{N}(\mu_0^N, \Psi_i^N)} \overbrace{p(\mu_0^N | \theta_0)}^{\mathcal{N}(0, K_{\theta_0})} \\
\ln p(\mu_0^N | (y_i^N)_i, \Theta) &= -\frac{1}{2} \mu_0^{NT} K_{\theta_0}^{-1} \mu_0^N - \frac{1}{2} \sum_{i=1}^M -2 y_i^{NT} \Psi_i^{N-1} \mu_0^N + \mu_0^{NT} \Psi_i^{N-1} \mu_0^N + C_1 \\
&= -\frac{1}{2} \mu_0^{NT} (K_{\theta_0}^{-1} + \sum_{i=1}^M \Psi_i^{N-1}) \mu_0^N - \mu_0^N \sum_{i=1}^M \Psi_i^{N-1} y_i^N + C_1
\end{aligned}$$

Ainsi:

$$p(\mu_0^N | (y_i^N)_i, \Theta) = \mathcal{N}(m^N, \hat{K}^N)$$

Avec:

- $\hat{K}^N = \left((K_{\theta_0}^N)^{-1} + \sum_{i=1}^M (\Psi_i^N)^{-1} \right)^{-1}$
- $m^N = \hat{K}^N \sum_{i=1}^M (\Psi_i^N)^{-1} y_i^N$

5 Les preuves associées

Pour les démonstrations, on va user et abuser du Lemme ci dessous.

Lemma 1. Pour un espace \mathcal{X} qui permet d'utiliser Fubini ,

$$\forall A, B \in \mathcal{X}, \quad \mathbb{E}_{p(A)} [g(A)] = \mathbb{E}_{p(B)} [\mathbb{E}_{p(A|B)} [g(A)]]$$

Proof.

$$\begin{aligned}
\mathbb{E}_{p(A)} [g(A)] &= \int g(A) p(A) dA \\
&= \int g(A) \int p(A, B) dB dA \\
&= \int \int g(A) p(A|B) p(B) dB dA \\
&\stackrel{\text{Fubini}}{=} \int \left(\int g(A) p(A|B) dA \right) p(B) dB \\
&= \mathbb{E}_{p(B)} [\mathbb{E}_{p(A|B)} [g(A)]]
\end{aligned}$$

□

5.1 Preuve de (1)

On sait que la convolution de deux gaussiennes est elle aussi gaussienne, il suffit donc de calculer ses paramètres à l'aide du Lemme 1 avec $A = y_*^N | (y_i^N)_i$ et $B = \mu_0^N | (y_i^N)_i$

$$\begin{aligned}
m_*^N &= \mathbb{E}_{p(y_*^N | (y_i^N)_i)} [y_*^N] \\
&= \mathbb{E}_{p(\mu_0^N | (y_i^N)_i)} \left[\mathbb{E}_{p(y_*^N | (y_i^N)_i, \mu_0^N)} [y_*^N] \right] \\
&= \mathbb{E}_{p(\mu_0^N | (y_i^N)_i)} \left[\mathbb{E}_{p(y_*^N | y_i^{t_i}, \mu_0^{t_i^*})} [y_*^N] \right] \\
&= \mathbb{E}_{p(\mu_0^N | (y_i^N)_i)} [\mu_0^N] \\
&= m^N
\end{aligned}$$

On calcule ensuite le moment d'ordre 2:

$$\begin{aligned}
\mathbb{E}_{p(y_*^N | (y_i^N)_i)} [y_*^N y_*^{N^T}] &= \mathbb{E}_{p(\mu_0^N | (y_i^N)_i)} \left[\mathbb{E}_{p(y_*^N | (y_i^N)_i, \mu_0^N)} [y_*^N y_*^{N^T}] \right] \\
&= \mathbb{E}_{p(\mu_0^N | (y_i^N)_i)} \left[\underbrace{\Psi_*^N}_{\mathbb{V}_{p(y_*^N | (y_i^N)_i)} [y_*^N]} + \underbrace{\mu_0^N \mu_0^{N^T}}_{\mathbb{E}_{p(y_*^N | (y_i^N)_i)} [y_*^N] \mathbb{E}_{p(y_*^N | (y_i^N)_i)} [y_*^{N^T}]} \right] \\
&= \Psi_*^N + \mathbb{E}_{p(\mu_0^N | (y_i^N)_i)} [\mu_0^N \mu_0^{N^T}] \\
&= \Psi_*^N + \underbrace{\hat{K}^N}_{\mathbb{V}_{p(\mu_0^N | (y_i^N)_i)} (\mu_0^N)} + \underbrace{m^N m^{N^T}}_{\mathbb{E}_{p(\mu_0^N | (y_i^N)_i)} [\mu_0^N] \mathbb{E}_{p(\mu_0^N | (y_i^N)_i)} [\mu_0^{N^T}]}
\end{aligned}$$

Ainsi:

$$\begin{aligned}
\Gamma_*^N &= \mathbb{V}_{p(y_*^N | (y_i^N)_i)} [y_*^N] \\
&= \mathbb{E}_{p(y_*^N | (y_i^N)_i)} [y_*^N y_*^{N^T}] - \mathbb{E}_{p(y_*^N | (y_i^N)_i)} [y_*^N] \mathbb{E}_{p(y_*^N | (y_i^N)_i)} [y_*^{N^T}] \\
&= \Psi_*^N + \hat{K}^N + m^N m^{N^T} - m^N m^{N^T} \\
&= \Psi_*^N + \hat{K}^N
\end{aligned}$$

6 Model with clustering - variational EM

6.1 Notations

- M le nombre d'individus,
- N le nombre d'observation par individu,
- i, j les indices pour les individus,
- k, l les indices pour les observations,

On dispose d'un échantillon $\{(y_i^N, t_i^N)\}_{i=1, \dots, M}$, tel que:

- $t^N = (t_1, \dots, t_N)^T$ le vecteur des temps de l'individu i (communs à tous),
- $y_i^N = y_i(t^N) = (y_i(t_1), \dots, y_i(t_N))^T$ le vecteur des observations de l'individu i ,
- $t^O \in \mathbb{R}^O$, $t^O \subset t^N$ le vecteur des temps d'observation d'un nouvel individu $*$,
- $t^P \in \mathbb{R}^P$, $t^P \subset t^N$ le vecteur des temps à prédire d'un nouvel individu $*$,
- $O + P = N$ et $t_i^O \cup t_i^P = t_i^N, \forall i$
- $y_i^O = y_i(t^O)$, $y_i^P = y_i(t^P)$, $\forall i$
- K_{θ_0} une noyau d'hyperparamètres θ_0

- $(\Sigma_{\theta_i})_i$ un ensemble de noyau de même forme et d'hyperparamètres respectifs $(\theta_i)_i$
- $\sigma^2 \in R$
- $\Theta = \{\theta_0, (\theta_i)_i, \sigma^2\}$ le vecteur des hyperparamètres du modèle

L'utilisation des indices avec les autres objets est cohérente avec celle ci-dessus.

6.2 Learning

6.2.1 E step

$$\log p(y|\pi, \theta, \gamma, \sigma^2) = \mathcal{L}(r(\mu, Z); \pi, \theta, \gamma, \sigma^2) + KL(r(\mu, Z) || p(\mu, Z)|y, \pi, \theta, \gamma, \sigma^2)$$

We assume that $r(\mu, Z) = r(\mu)r(Z)$. Considering this variational hypothesis, we know from *ref variational*, that the optimal functions are $\hat{r}(\mu)$, and $\hat{r}(Z)$ defined as such:

6.2.1.1 Calculation of $\hat{r}(\mu)$

$$\begin{aligned} \log \hat{r}(\mu) &= \mathbb{E}_Z [\log p(y, Z, \mu | \pi, \theta, \gamma, \sigma^2)] + C_1 \\ &= \mathbb{E}_Z [\log p(y | Z, \mu, \pi, \gamma, \sigma^2)] + \log p(\mu | \theta) + C_2 \\ &= \sum_{i=1}^M \mathbb{E}_{Z_i} [\log p(y_i | Z_i, \mu, \gamma_i, \sigma_i^2)] + \sum_{q=1}^Q \log p(\mu_q | \theta_q) + C_2 \\ &= \sum_{i=1}^M \mathbb{E}_{Z_i} \left[\sum_{q=1}^Q Z_{iq} \log p(y_i | \mu_q, \gamma_i, \sigma_i^2) \right] + \sum_{q=1}^Q \log p(\mu_q | \theta_q) + C_2 \\ &= \sum_{q=1}^Q \left\{ -\frac{1}{2} (\mu_q - m_q)^T K_{\theta_q}^{-1} (\mu_q - m_q) - \frac{1}{2} \sum_{i=1}^M \tau_{iq} (y_i - \mu_q) \Psi_{\gamma_i, \sigma_i^2}^{-1} (y_i - \mu_q) \right\} + C_3 \\ &= -\frac{1}{2} \mu_q^T \left(K_{\theta_q}^{-1} + \sum_{i=1}^M \tau_{iq} \Psi_{\gamma_i, \sigma_i^2}^{-1} \right) \mu_q + \mu_q^T \left(K_{\theta_q}^{-1} m_q + \sum_{i=1}^M \tau_{iq} \Psi_{\gamma_i, \sigma_i^2}^{-1} y_i \right) + C_4 \end{aligned}$$

We identify a gaussian likelihood and thus:

$$\begin{aligned} \hat{r}(\mu) &= \prod_{q=1}^Q \hat{r}(\mu_q) \\ &= \prod_{q=1}^Q \mathcal{N}(\mu_q; \hat{\mu}_q, \hat{K}_q), \end{aligned}$$

with:

- $\hat{K}_q = \left(K_{\theta_q}^{-1} + \sum_{i=1}^M \tau_{iq} \Psi_{\gamma_i, \sigma_i^2}^{-1} \right)^{-1}$,
- $\hat{\mu}_q = \hat{K}_q \left(K_{\theta_q}^{-1} m_q + \sum_{i=1}^M \tau_{iq} \Psi_{\gamma_i, \sigma_i^2}^{-1} y_i \right)$.

6.2.1.2 Calculation of $\hat{r}(Z)$

$$\begin{aligned}
\log \hat{r}(Z) &= \mathbb{E}_\mu [\log p(y, Z, \mu | \pi, \theta, \gamma, \sigma^2)] + C_1 \\
&= \mathbb{E}_\mu [\log p(y | Z, \mu, \gamma, \sigma^2)] + \log p(Z | \pi) + C_2 \\
&= \mathbb{E}_\mu \left[\sum_{i=1}^M \sum_{q=1}^Q Z_{iq} \log p(y_i | \mu_q, \gamma_i, \sigma_i^2) \right] + \sum_{i=1}^M \sum_{q=1}^Q Z_{iq} \log(\pi_q) + C_2 \\
&= \sum_{i=1}^M \sum_{q=1}^Q Z_{iq} \left\{ \log(\pi_q) - \frac{1}{2} \left(\log |\Psi_{\gamma_i, \sigma_i^2}| + \mathbb{E}_\mu \left[(y_i - \mu_q) \Psi_{\gamma_i, \sigma_i^2}^{-1} (y_i - \mu_q) \right] \right) \right\} + C_3 \\
&= \sum_{i=1}^M \sum_{q=1}^Q Z_{iq} \left\{ \log(\pi_q) - \frac{1}{2} \left(\log |\Psi_{\gamma_i, \sigma_i^2}| + (y_i - \hat{\mu}_q) \Psi_{\gamma_i, \sigma_i^2}^{-1} (y_i - \hat{\mu}_q) - \text{Tr}(\Psi_{\gamma_i, \sigma_i^2}^{-1} \hat{K}_q) \right) \right\} + C_3
\end{aligned}$$

By identification, we found that $\hat{r}(Z) = \sum_{i=1}^M \hat{r}(Z_i)$ with:

- $\hat{r}(Z_i) = \mathcal{M}(1, \tau_{iq})$,
- $\log \tau_{iq} = \log(\pi_q) - \frac{1}{2} \left(\log |\Psi_{\gamma_i, \sigma_i^2}| + (y_i - \hat{\mu}_q) \Psi_{\gamma_i, \sigma_i^2}^{-1} (y_i - \hat{\mu}_q) - \text{Tr}(\Psi_{\gamma_i, \sigma_i^2}^{-1} \hat{K}_q) \right) + C_4$,
- $\tau_{iq} = \frac{\pi_q \mathcal{N}(y_i, \hat{\mu}_q, \Psi_{\gamma_i, \sigma_i^2}) \exp \left(-\frac{1}{2} \text{Tr}(\Psi_{\gamma_i, \sigma_i^2}^{-1} \hat{K}_q) \right)}{\sum_{l=1}^Q \pi_l \mathcal{N}(y_i, \hat{\mu}_l, \Psi_{\gamma_i, \sigma_i^2}) \exp \left(-\frac{1}{2} \text{Tr}(\Psi_{\gamma_i, \sigma_i^2}^{-1} \hat{K}_l) \right)}$.

6.2.2 M step

By explicit optimization, we get that:

$$\hat{\pi}_q = \frac{1}{M} \sum_{i=1}^M \tau_{iq}, \quad \forall q = 1, \dots, Q.$$

Proposition 1. Let Θ be $\{\theta, \gamma, \sigma^2\}$,

$$\begin{aligned}
\hat{\Theta} &= \arg \max_{\Theta} -\frac{1}{2} \sum_{i=1}^M \left\{ \log |\Psi_{\gamma_i, \sigma_i^2}| + y_i^T \Psi_{\gamma_i, \sigma_i^2}^{-1} y_i - 2 y_i^T \Psi_{\gamma_i, \sigma_i^2}^{-1} \sum_{q=1}^Q \tau_{iq} \hat{\mu}_q + \text{Tr}(\Psi_{\gamma_i, \sigma_i^2}^{-1} \sum_{q=1}^Q \tau_{iq} \hat{\mu}_q^T \hat{\mu}_q) + \text{Tr}(\Psi_{\gamma_i, \sigma_i^2}^{-1} \sum_{q=1}^Q \tau_{iq} \hat{K}_q) \right\} \\
&\quad + \sum_{q=1}^Q \left\{ \log |K_{\theta_q}| + (\hat{\mu}_q - m_q)^T K_{\theta_q}^{-1} (\hat{\mu}_q - m_q) + \text{Tr}(K_{\theta_q}^{-1} \hat{K}_q) \right\}
\end{aligned}$$

Proof.

$$\begin{aligned}
\mathcal{L}(r(\mu, Z); \pi, \theta, \gamma, \sigma^2) &= \mathbb{E}_{\mu, Z} [\log p(y, Z, \mu | \pi, \theta, \gamma, \sigma^2)] - \underbrace{\mathbb{E}_{\mu, Z} [\log r(\mu, Z)]}_{constant} \\
&= \mathbb{E}_{\mu, Z} [\log p(y | Z, \mu, \gamma, \sigma^2)] + \mathbb{E}_{\mu} [\log p(\mu | \theta)] + \mathbb{E}_Z [\log p(Z | \pi)] + C_1 \\
&= \sum_{i=1}^M \sum_{q=1}^Q \tau_{iq} \left\{ -\frac{1}{2} \log |\Psi_{\gamma_i, \sigma_i^2}| - \frac{1}{2} (y_i - \hat{\mu}_q)^T \Psi_{\gamma_i, \sigma_i^2}^{-1} (y_i - \hat{\mu}_q) - \frac{1}{2} \text{Tr}(\Psi_{\gamma_i, \sigma_i^2}^{-1} \hat{K}_q) \right\} \\
&\quad + \sum_{q=1}^Q \left\{ -\frac{1}{2} \log |K_{\theta_q}| - \frac{1}{2} (\hat{\mu}_q - m_q)^T K_{\theta_q}^{-1} (\hat{\mu}_q - m_q) - \frac{1}{2} \text{Tr}(K_{\theta_q}^{-1} \hat{K}_q) \right\} \\
&\quad + \sum_{i=1}^M \tau_{iq} \log(\pi_q) + C_1
\end{aligned}$$

□

6.3 Mean processes update

6.4 Prediction